

Лабораторная работа №4

Многомерная минимизация: градиентный метод с дроблением шага
и модификация Марквардта

1 Постановка задачи

Дана функция двух переменных:

$$f(x_1, x_2) = x_1 + 3x_2 + e^{x_1^2 + x_2^2}.$$

Требуется найти точку безусловного минимума:

$$f(x) \rightarrow \min, \quad x = (x_1, x_2) \in \mathbb{R}^2.$$

Задания:

1. Решить задачу **градиентным методом 1-го порядка с дроблением шага**.
2. Указать оценку абсолютной погрешности полученного решения.
3. Предложить **модификацию метода** (выбор направления спуска) — метод Марквардта:

$$d_k = -(H(x_k) + \mu_k I)^{-1} \nabla f(x_k),$$

с тем же способом выбора шага (дробление). Решить задачу и сравнить с методом 1-го порядка.

2 Исследование применимости методов

2.1 Гладкость

Функция $f(x) = x_1 + 3x_2 + e^{x_1^2 + x_2^2}$ является бесконечно дифференцируемой: $f \in C^\infty(\mathbb{R}^2)$, т. к. она является суммой линейной функции и композиции экспоненты (гладкой) с квадратичной (гладкой).

2.2 Градиент

$$\nabla f(x) = \begin{pmatrix} 1 + 2x_1 e^{x_1^2 + x_2^2} \\ 3 + 2x_2 e^{x_1^2 + x_2^2} \end{pmatrix}.$$

2.3 Матрица Гессе

Обозначим $q(x) = x_1^2 + x_2^2$. Тогда:

$$H(x) = e^q \cdot \begin{pmatrix} 2 + 4x_1^2 & 4x_1 x_2 \\ 4x_1 x_2 & 2 + 4x_2^2 \end{pmatrix}.$$

Вычисление (для компоненты h_{11}):

$$\frac{\partial^2 f}{\partial x_1^2} = \frac{\partial}{\partial x_1} (1 + 2x_1 e^q) = 2e^q + 2x_1 \cdot 2x_1 e^q = e^q (2 + 4x_1^2).$$

Аналогично $h_{22} = e^q (2 + 4x_2^2)$, $h_{12} = h_{21} = 4x_1 x_2 e^q$.

2.4 Строгая выпуклость

Утверждение: f строго выпукла на $\mathbb{R}^2$ (т.е. $H(x) \succ 0$ при всех x).

Доказательство. Обозначим внутреннюю матрицу $A = \begin{pmatrix} 2 + 4x_1^2 & 4x_1x_2 \\ 4x_1x_2 & 2 + 4x_2^2 \end{pmatrix}$. Множитель $e^q > 0$ всегда, поэтому $H \succ 0 \Leftrightarrow A \succ 0$.

Проверка по критерию Сильвестра:

- $a_{11} = 2 + 4x_1^2 \geq 2 > 0 \quad \checkmark$
 - $\det A = (2 + 4x_1^2)(2 + 4x_2^2) - 16x_1^2x_2^2$
 $= 4 + 8x_1^2 + 8x_2^2 + 16x_1^2x_2^2 - 16x_1^2x_2^2 = 4 + 8x_1^2 + 8x_2^2 \geq 4 > 0 \quad \checkmark$
- $\Rightarrow A \succ 0$ при всех $x \in \mathbb{R}^2 \Rightarrow H(x) \succ 0 \Rightarrow f$ строго выпукла.

2.5 Коэрцитивность

При $\|x\| \rightarrow \infty$: $e^{x_1^2+x_2^2} \rightarrow +\infty$ экспоненциально, в то время как линейная часть $x_1 + 3x_2$ растёт не быстрее $\|x\| \cdot \sqrt{10}$. Следовательно, $f(x) \rightarrow +\infty$ при $\|x\| \rightarrow \infty$.

Конкретно: для $\|x\| \geq R$ при достаточно большом R :

$$e^{\|x\|^2} \gg |x_1 + 3x_2| \leq \sqrt{10} \|x\|,$$

поэтому $f(x) \geq e^{\|x\|^2} - \sqrt{10} \|x\| \rightarrow +\infty$.

2.6 Существование и единственность минимума

1. f — непрерывна и коэрцитивна $\Rightarrow$ по теореме Вейерштрасса существует глобальный минимум.
 2. f — строго выпукла $\Rightarrow$ локальный минимум единственный и совпадает с глобальным.
- $\Rightarrow \exists! x^* \in \mathbb{R}^2: f(x^*) = \min_{x \in \mathbb{R}^2} f(x)$.

2.7 Применимость градиентного метода

Градиент ∇f непрерывен и удовлетворяет условию Липшица на любом ограниченном множестве (т.к. все вторые производные непрерывны). Следовательно, метод градиентного спуска с дроблением шага (условие Армихо) сходится к x^* .

2.8 Применимость метода Марквардта

Метод Марквардта использует $d_k = -(H_k + \mu_k I)^{-1} \nabla f_k$. Поскольку $H(x) \succ 0$ при всех x , матрица $(H + \mu I)$ также положительно определена для любого $\mu \geq 0$ и всегда обратима. При $\mu \rightarrow 0$ метод приближается к методу Ньютона, при $\mu \rightarrow \infty$ — к методу наискорейшего спуска (с малым шагом).

3 Описание алгоритмов

3.1 Алгоритм 1: Градиентный спуск с дроблением шага

Вход: начальная точка x_0 , параметры $\alpha_0 > 0$, $\beta \in (0, 1)$, $c_1 \in (0, 1)$, точность $\varepsilon > 0$.

Шаги ($k = 0, 1, 2, \dots$):

1. Вычислить $g_k = \nabla f(x_k)$.
2. **Критерий останова:** если $\|g_k\| < \varepsilon$, то СТОП, $x^* := x_k$.
3. Направление спуска: $d_k = -g_k$.
4. Выбор шага (дробление — условие Армихо):
 - Положить $\alpha := \alpha_0$.
 - Пока $f(x_k + \alpha d_k) > f(x_k) + c_1 \alpha \langle g_k, d_k \rangle$: $\alpha := \beta \cdot \alpha$.
5. Обновление: $x_{k+1} = x_k + \alpha_k d_k$.

Параметры: $\alpha_0 = 1$, $\beta = 0,5$ (деление пополам), $c_1 = 10^{-4}$, $\varepsilon = 10^{-6}$.

Ручной счёт — итерация $k = 0$ (начало из $x_0 = (0; 0)$):

$$f(x_0) = 0 + 0 + e^0 = 1.$$

$$g_0 = (1 + 0, 3 + 0) = (1, 3), \quad \|g_0\| = \sqrt{10} \approx 3,162, \quad d_0 = (-1, -3).$$

$$\langle g_0, d_0 \rangle = -10.$$

Проверка шага:

• $\alpha = 1$: $x_0 + d_0 = (-1, -3)$, $f(-1, -3) = -1 - 9 + e^{10} \approx 22016 \gg 1 - 0,001 = 0,999$.
Дробим.

• $\alpha = 0,5$: $x = (-0,5, -1,5)$, $f = -0,5 - 4,5 + e^{2,5} \approx 7,18$. Дробим.

• $\alpha = 0,25$: $x = (-0,25, -0,75)$, $f = -0,25 - 2,25 + e^{0,625} \approx -0,632$.

$$\text{Проверка: } f(x_0) + c_1 \cdot 0,25 \cdot (-10) = 1 - 0,0025 = 0,9975.$$

$$-0,632 < 0,9975 \quad \checkmark \quad \text{— шаг принят.}$$

Итого: $\alpha_0 = 0,25$, $x_1 = (-0,25; -0,75)$, $f(x_1) \approx -0,632$, дроблений: 2.

3.2 Алгоритм 2: Метод Марквардта с дроблением шага

Вход: начальная точка x_0 , начальный параметр $\mu_0 > 0$, параметры α_0 , β , c_1 , ε — как в Алгоритме 1.

Шаги ($k = 0, 1, 2, \dots$):

1. Вычислить $g_k = \nabla f(x_k)$, $H_k = H(x_k)$.
2. **Критерий останова:** если $\|g_k\| < \varepsilon$, то СТОП.
3. Направление спуска:
$$d_k = -(H_k + \mu_k I)^{-1} g_k.$$
4. Выбор шага — дробление (как в Алгоритме 1).

5. Адаптация μ_k :

- $\rho_k = \frac{f(x_k) - f(x_{k+1})}{-\langle g_k, \alpha_k d_k \rangle - \frac{1}{2} \langle \alpha_k d_k, H_k(\alpha_k d_k) \rangle}$ — отношение фактического к предсказанному уменьшению.
- Если $\rho_k > 0,75$: $\mu_{k+1} = \mu_k/2$ (ближе к Ньютону).
- Если $\rho_k < 0,25$: $\mu_{k+1} = 2\mu_k$ (ближе к градиентному спуску).
- Иначе: $\mu_{k+1} = \mu_k$.

6. $x_{k+1} = x_k + \alpha_k d_k$.

Параметры: $\mu_0 = 10$, остальные как в Алгоритме 1.

Ручной счёт — итерация $k = 0$ (начало из $x_0 = (0; 0)$):

$$g_0 = (1, 3)^T, \quad H_0 = e^0 \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix} = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}.$$

$$H_0 + \mu_0 I = \begin{pmatrix} 12 & 0 \\ 0 & 12 \end{pmatrix}, \quad (H_0 + \mu_0 I)^{-1} = \frac{1}{12} \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}.$$

$$d_0 = -\frac{1}{12}(1, 3)^T = (-1/12, -1/4).$$

$$\langle g_0, d_0 \rangle = -1/12 - 3/4 = -5/6.$$

$$\text{При } \alpha = 1: x_1 = (0, 0) + (-1/12, -1/4) = (-0,0833; -0,2500).$$

$$f(x_1) = -0,0833 - 0,7500 + e^{0,0069+0,0625} = -0,8333 + e^{0,0694} \approx -0,8333 + 1,0719 = 0,239.$$

$$\text{Проверка: } f(x_0) + c_1 \alpha \langle g_0, d_0 \rangle = 1 + 10^{-4} \cdot (-5/6) \approx 0,9999.$$

$$0,239 < 0,9999 \quad \checkmark \quad \text{— шаг принят без дробления, } \alpha_0 = 1.$$

4 Результат решения задачи

4.1 Метод градиентного спуска с дроблением шага

Начальная точка $x_0 = (0; 0)$, $\varepsilon = 10^{-6}$.

k	$x_1^{(k)}$	$x_2^{(k)}$	$f(x_k)$	$\ \nabla f\ $	α_k
0	0,0000	0,0000	1,0000	3,162	—
1	-0,2500	-0,7500	-0,6318	0,208	0,25
2	-0,2582	-0,7747	-0,6343	0,019	0,125
3	-0,2575	-0,7724	-0,63427	0,0026	0,125
4	-0,2576	-0,7727	-0,63427	$3,3 \cdot 10^{-4}$	0,125
5	-0,2576	-0,7727	-0,63427	$4,3 \cdot 10^{-5}$	0,125
6	-0,2576	-0,7727	-0,63427	$5,5 \cdot 10^{-6}$	0,125
7	-0,2576	-0,7727	-0,63427	$7,1 \cdot 10^{-7}$	0,125

Сходимость за **7 итераций**. На каждой итерации (кроме первой) — 3 дробления шага.

4.2 Метод Марквардта

Начальная точка $x_0 = (0; 0)$, $\mu_0 = 10$, $\varepsilon = 10^{-6}$.

k	$x_1^{(k)}$	$x_2^{(k)}$	$f(x_k)$	$\ \nabla f\ $	α_k	μ_k
0	0,0000	0,0000	1,0000	3,162	—	10
1	-0,0833	-0,2500	0,239	2,597	1	5
2	-0,1937	-0,5811	-0,482	1,379	1	2,5
3	-0,2511	-0,7534	-0,632	0,178	1	1,25
4	-0,2569	-0,7707	-0,6343	0,0185	1	0,625
5	-0,2575	-0,7726	-0,63427	0,00115	1	0,3125
6	-0,2576	-0,7727	-0,63427	$3,8 \cdot 10^{-5}$	1	0,156
7	-0,2576	-0,7727	-0,63427	$6,5 \cdot 10^{-7}$	1	0,078

Сходимость за **7 итераций**. Шаг дробления **не потребовался** ($\alpha = 1$ на каждой итерации). Параметр μ убывает от 10 до 0,078 (метод приближается к Ньютону).

4.3 Ответ

$$x^* \approx (-0,2576; -0,7727), \quad f(x^*) \approx -0,6343.$$

С точностью до 4 знаков после запятой:

$$x_1^* = -0,2576, \quad x_2^* = -0,7727, \quad f^* = -0,6343.$$

4.4 Оценка абсолютной погрешности

Для градиентного метода с линейной скоростью сходимости:

$$\|x_k - x^*\| \leq \frac{q}{1 - q} \|x_k - x_{k-1}\|,$$

где $q = \frac{L - m}{L + m}$, m, L — наименьшее и наибольшее собственные значения $H(x^*)$.

Вычисление:

Собственные значения $H(x^*)$:

$$H(x^*) = e^{q^*} \begin{pmatrix} 2 + 4(x_1^*)^2 & 4x_1^*x_2^* \\ 4x_1^*x_2^* & 2 + 4(x_2^*)^2 \end{pmatrix},$$

где $q^* = (x_1^*)^2 + (x_2^*)^2 \approx 0,0663 + 0,5971 = 0,6634$, $e^{q^*} \approx 1,941$.

$$H(x^*) \approx \begin{pmatrix} 4,398 & 1,545 \\ 1,545 & 8,519 \end{pmatrix}.$$

Собственные значения: $\lambda_1 \approx 3,883$, $\lambda_2 \approx 9,034$.

$$m = 3,883, \quad L = 9,034, \quad q = \frac{9,034 - 3,883}{9,034 + 3,883} = \frac{5,151}{12,917} \approx 0,399.$$

На последней итерации градиентного метода: $\|x_7 - x_6\| \approx 6,9 \cdot 10^{-7}$.

$$\|x_7 - x^*\| \leq \frac{0,399}{0,601} \cdot 6,9 \cdot 10^{-7} \approx 4,6 \cdot 10^{-7}.$$

5 Обоснование решения

5.1 Необходимое условие оптимальности

В точке минимума x^* необходимо: $\nabla f(x^*) = 0$.

$$\left. \frac{\partial f}{\partial x_1} \right|_{x^*} = 1 + 2 \cdot (-0,2576) \cdot e^{0,6634} = 1 + (-0,5152) \cdot 1,941 \approx 1 - 1,000 = 0,000. \checkmark$$

$$\left. \frac{\partial f}{\partial x_2} \right|_{x^*} = 3 + 2 \cdot (-0,7727) \cdot e^{0,6634} = 3 + (-1,5454) \cdot 1,941 \approx 3 - 2,999 = 0,001 \approx 0. \checkmark$$

5.2 Достаточное условие оптимальности

В точке x^* проверяем положительную определённую гессиана:

$$H(x^*) \approx \begin{pmatrix} 4,398 & 1,545 \\ 1,545 & 8,519 \end{pmatrix}.$$

Критерий Сильвестра:

- $\Delta_1 = 4,398 > 0 \checkmark$
 - $\Delta_2 = 4,398 \cdot 8,519 - 1,545^2 = 37,47 - 2,39 = 35,08 > 0 \checkmark$
- $\Rightarrow H(x^*) \succ 0 \Rightarrow x^*$ — точка **строгого локального минимума**.

5.3 Глобальность минимума

Ранее доказано: f строго выпукла на $\mathbb{R}^2$ (гессиан $H(x) \succ 0$ при всех x). Поэтому единственная стационарная точка x^* является **глобальным минимумом**.

5.4 Связь между координатами минимума

Из системы $\nabla f = 0$:

$$x_1 = -\frac{1}{2e^{q^*}}, \quad x_2 = -\frac{3}{2e^{q^*}},$$

откуда $x_2 = 3x_1$. Проверка: $(-0,7727)/(-0,2576) = 2,999 \approx 3. \checkmark$

6 Сравнительный анализ методов

Характеристика	Градиентный спуск	Марквардт
Число итераций	7	7
Дроблений шага (на итерацию)	2-3	0
Шаг α (типичный)	0,125	1
Вычислений f	~ 34	~ 14
Вычислений ∇f	7	7
Вычислений H	—	7
Порядок сходимости	Линейный ($q \approx 0,40$)	Сверхлинейный

Выводы:

1. Оба метода сходятся к одной и той же точке $x^* \approx (-0,2576; -0,7727)$.
2. **Метод Марквардта** принимает шаг $\alpha = 1$ без дробления, что означает, что направление спуска выбрано значительно лучше, чем антиградиент. Это существенно уменьшает число обращений к f (14 против 34).
3. Градиентный спуск использует $d_k = -\nabla f_k$ (направление наискорейшего убывания), но не учитывает кривизну функции. Метод Марквардта использует информацию второго порядка через гессиан, что позволяет выбирать более оптимальное направление.
4. Число μ в методе Марквардта управляет балансом между «осторожностью» (большое μ — шаг как в градиентном спуске) и «агрессивностью» (малое μ — шаг как в методе Ньютона). В данной задаче μ быстро уменьшается ($10 \rightarrow 0,078$), что показывает, что метод эффективно переключается на квадратичную сходимость Ньютона.
5. Для данной задачи число обусловленности $\kappa = L/m \approx 2,33$ невелико, поэтому градиентный спуск тоже сходится быстро. Для плохо обусловленных задач преимущество метода Марквардта было бы значительно больше.
6. **Рекомендация:** метод Марквардта предпочтительнее, если вычисление гессиана не является чрезмерно дорогим. Для задач большой размерности, где гессиан дорого вычислять и хранить, метод градиентного спуска может быть практичнее.